

## למידה עמוקה

### Automatic License Plate Recognition – ALPR

#### תקציר

פרויקט זה מציג פיתוח מערכת קצה-לקצה לזיהוי אוטומטי של לוחיות רישוי ברכבים הודיים, במסגרת משימת Automatic License Plate Recognition (ALPR). מטרת המערכת היא לאתר את מיקום הלוחית בתמונת רכב, לחלץ ולעבד אותה, ובהמשך לאפשר קריאה אוטומטית של התווים המופיעים עליה. המערכת נבנתה באופן מודולרי באמצעות TensorFlow/Keras ו-OpenCV, ללא שימוש בגלאי עצמים מוכנים מראש כגון YOLO, מתוך מטרה להבין וליישם את שלבי הראייה הממוחשבת והלמידה העמוקה באופן עצמאי.

הארכיטקטורה כוללת שלושה שלבים עיקריים: מודל Detection המבוסס על MobileNetV2 ומבצע גרסיה לתיבה תוחמת יחידה; שלב Preprocessing הכולל חיתוך הלוחית, יישור פרספקטיבה, המרה לגווני אפור ושיפור ניגודיות באמצעות CLAHE, ושלב OCR המבוסס על CRNN ו-CTC לקריאת רצף התווים. מאגר הנתונים הגולמי כלל כ-1,700 תמונות ממספר מקורות. לאחר ניקוי נתונים, הסרת כפילויות וסינון אנוטציות שגויות, נותרו 1,092 דוגמאות שחולקו ל-Train, Validation ו-Test תוך מניעת זליגת מידע.

ממצאי הפרויקט מצביעים כי איכות איתור הלוחית מהווה גורם מרכזי בביצועי המערכת הכוללת: בעוד שמודל ה-OCR הגיע לדיקו Exact Match של כ-46% על חיתוכי Ground Truth, דיוק המערכת המלאה עמד על 23.1%. במדדי האיתור נצפתה שונות בין ריצות, כאשר Mean IoU נע בטווח של כ-0.35–0.41. מכאן עולה כי שיפור רכיב ה-Detection הוא הכיוון המרכזי לשיפור עתידי של המערכת.

#### 1. מבוא

זיהוי אוטומטי של לוחיות רישוי, Automatic License Plate Recognition (ALPR), הוא יישום מרכזי בתחום הראייה הממוחשבת, ומשמש במערכות תחבורה חכמות, בקרת כניסה, אכיפה וניהול חניונים. מטרת מערכת ALPR היא לקבל תמונת רכב, לאתר את מיקום הלוחית הרישוי, לחלץ אותה מהתמונה ולזהות את רצף התווים המופיע עליה.

האתגר המרכזי במשימה זו נובע מכך שהתמונות נאספות לרוב בתנאים לא מבוקרים. בפועל, לוחיות הרישוי עשויות להופיע בזוויות צילום שונות, בתנאי תאורה משתנים, ברזולוציות נמוכות או עם טשטוש ורעשי רקע. גורמים אלו מקשים הן על איתור מדויק של הלוחית והן על קריאת התווים בשלבים המאוחרים של המערכת.

בפרויקט זה התמקדנו בזיהוי לוחיות רישוי הודיות, המאופיינות במבנה סמנטי מוגדר הכולל קוד מדינה, קוד מחוז, סדרה ומספר רישוי, לדוגמה MH20TC830C. העבודה התבססה על בניית צינור עיבוד מודולרי המורכב משלושה שלבים: איתור הלוחית בתמונה, עיבוד מקדים של אזור הלוחית, וזיהוי התווים באמצעות OCR.

בגלל שזו מטלה כחלק מקורס המוטיבציה המרכזית שלנו הייתה לבנות מערכת שקופה וניתנת לניתוח, כדי שנוכל להבין כיצד כל שינוי משפיע, ומכאן הבחירה לא להשתמש בגלאי עצמים מוכנים מראש כגון YOLO. בחירה זו אפשרה לבחון באופן ישיר את השפעת רכיבי המערכת השונים, לרבות הארכיטקטורה, פונקציות ההפסד, תהליך האימון וההיפר פרמטרים, על ביצועי המודל. מטרת העבודה היא לא דווקא להשיג מודל מוכן לפרודקשין עם הציון הכי טוב, אלא בעיקר להתנסות ולהבין את תרומתו של כל שלב בצינור העיבוד ואת השפעת איכות האיתור על הצלחת שלב קריאת התווים.


## למידה עמוקה

במסגרת הפרויקט נבחנה גישה של ראש רגרסיה לתיבה תוחמת יחידה עבור איתור הלוחית (בכל תמונה אמורה להיות לוחית), ולאחר מכן בוצע עיבוד מקדים שכלל חיתוך, יישור פרספקטיבה ושיפור ניגודיות. גישה זו מאפשרת לנתח את המערכת באופן הדרגתי, לזהות את צווארי הבקבוק העיקריים, ולהעריך אילו רכיבים דורשים שיפור בהמשך הפיתוח.

### 2. נתונים

הפרויקט התבסס על מאגר התמונות Indian Vehicle Dataset מתוך Kaggle, המיועד לשימושים זיהוי לוחיות רישוי ברכבים הודיים. המאגר הגולמי כלל כ-1,700 תמונות רכבים, כאשר לכל תמונה צורפה אנוטציה בפורמט Pascal VOC XML. כל אנוטציה כוללת את מיקום הלוחית הרישוי באמצעות תיבה תוחמת, וכן את טקסט הלוחית. בהתאם לכך, משתני הקלט במערכת הם תמונות הרכב, ואילו משתני המטרה הם ארבעת קואורדינטות התיבה התוחמת בשלב ה-Detection, ורצף התווים של הלוחית בשלב ה-OCR.

הנתונים נאספו משלושה מקורות שונים: תמונות ממנוע החיפוש Google, פריימים מתוך סרטוני וידאו, ותמונות מוקטנות (thumbnail) מאתר המודעות ההודי State-wise OLX. בנתונים מגוון רחב של תנאי צילום, הכוללים הבדלים בזוויות הצילום, תאורה, רזולוציה, חדות ואיכות כללית של התמונה. לאחר קריאת קבצי האנוטציה באמצעות הפונקציה parse\_voc, התקבלו 1,592 אנוטציות תקינות.



בשלב הכנת הנתונים בוצעו מספר פעולות ניקוי וסינון. תחילה הוסרו אנוטציות שאינן תקינות, תוויות שאינן מייצגות מספרי רישוי, קבצים נלווים מסוג Zone.Identifier, ותיבות תוחמות לא תקינות (למשל בעלות שטח אפס או קואורדינטות הפוכות). בנוסף, בוצעה הסרת כפילויות, בעיקר עבור תמונות שמקורן בסרטוני וידאו. מאחר שבסרטונים אותה לוחית עשויה להופיע במספר פריימים עוקבים, נשמר עבור כל לוחית הפריים האיכותי ביותר, שהוגדר כפריים שבו התיבה התוחמת היא הגדולה ביותר. פעולה זו נועדה לצמצם חזרתיות בדאטה ולמנוע מצב שבו המודל נחשף שוב ושוב לדוגמאות כמעט זהות.

לאחר הניקוי והסרת הכפילויות נותרו 1,092 דוגמאות סופיות. חלוקת הנתונים ל-Train, Validation, ו-Test בוצעה בגישה של Plate-Aware Split, כלומר לפי זהות הלוחית עצמה ולא באופן אקראי לפי תמונה. החלוקה בוצעה ביחס 80/10/10 ברמת הלוחית הייחודית; מאחר שלכל לוחית מספר תמונות שונה (במיוחד לאחר הסרת הכפילויות), מספרי התמונות בפועל בכל סט סוטים במעט מיחס זה. מטרת גישה זו הייתה למנוע זליגת מידע בין הסטים, כך שלוחית שהופיעה בסט האימון לא תופיע גם בסט האימות או בסט המבחן. מניעה זו חשובה במיוחד במאגר הכולל פריימים דומים או תמונות חוזרות, משום שחלוקה אקראית רגילה עלולה להוביל להערכת יתר של ביצועי המודל.

- סט אימון (Train): 872 (~80%)
- סט אימות (Validation): 114 (~10%)

- סט מבחן (Test): 106 (~10%)

עבור שלב ה-Detection נבנו קבצי Manifest הכוללים את נתיבי התמונות ואת קואורדינטות התיבה התוחמת המנורמלות. עבור שלב ה-OCR נבנה מאגר נוסף של חיתוכי לוחיות, שבו כל לוחית עברה את תהליך העיבוד המקדים של המערכת: חיתוך, יישור פרספקטיבה, המרה לגווני אפור, שיפור ניגודיות באמצעות CLAHE, ושינוי גודל ל- $64 \times 256$  פיקסלים. כך נשמרה התאמה בין אופן הכנת הנתונים לבין אופן פעולת ה-Pipeline בזמן אמת, שבו פלט שלב האיתור משמש כקלט לשלב העיבוד המקדים וה-OCR.

### 3. מתודולוגיה

המערכת נבנתה כ-Pipeline מודולרי לזיהוי אוטומטי של לוחיות רישוי, המורכב משלושה שלבים עוקבים: איתור מיקום הלוחית בתמונה, עיבוד מקדים של אזור הלוחית, וזיהוי רצף התווים שעל גבי הלוחית. חלוקה זו מאפשרת לאמן ולהעריך כל רכיב בנפרד, ובמקביל לנתח את תרומתו לביצועי המערכת הכוללת. בהתאם לכך, ניתן להבחין בין שגיאות הנובעות מאיתור לא מדויק של הלוחית לבין שגיאות הנובעות מקריאת תווים שגויה.

#### 3.1 מודל איתור הלוחית Detection

בשלב הראשון נדרש לאתר את מיקום הלוחית הרישוי בתוך תמונת הרכב. מאחר שבמאגר הנתונים קיימת לוחית אחת בכל תמונה, בעיית האיתור נוסחה כבעיית רגרסיה לתיבה תוחמת יחידה, ולא כבעיית גילוי עצמים מרובת מחלקות. פלט המודל הוא ארבע קואורדינטות מנורמלות:  $(x_{min}', y_{min}', x_{max}', y_{max}')$ , המייצגות את גבולות הלוחית ביחס לממדי התמונה.

ארכיטקטורת המודל התבססה על MobileNetV2 כ-Backbone לחילוף מאפיינים חזותיים. הבחירה ב-MobileNetV2 נבעה מהיותה רשת קונבולוציונית קלת-משקל ויעילה, המתאימה למשימות שבהן נדרש איזון בין יכולת ייצוג טובה לבין עלות חישובית נמוכה יחסית. ה-Backbone נטען עם משקלים שאומנו מראש על ImageNet, ולאחריו נוספו שכבת Global Average Pooling ושכבת Dense בגודל 256 עם פונקציית הפעלה ReLU, שכבת Dropout לצמצום overfitting, ולבסוף שכבת Dense בעלת ארבע יציאות עם פונקציית Sigmoid. שימוש ב-Sigmoid מאפשר להחזיר את קואורדינטות התיבה בטווח  $[0,1]$ . מספר הפרמטרים הכולל עמד על כ-2.59 מיליון.

אימון מודל האיתור בוצע בשלושה שלבים הדרגתיים. בשלב הראשון, Huber Warmup, המודל אומן באמצעות Huber Loss בלבד, במטרה להביא את התחזיות הראשוניות לאזור סביר של הלוחית לפני שימוש ברכיב חפיפה מורכב יותר. בשלב השני נוספה פונקציית הפסד המבוססת על GIoU, כלומר Generalized Intersection over Union, שמטרתה לשפר את איכות החפיפה בין התיבה החזויה לתיבה האמיתית. בשלב השלישי בוצע Fine-tuning ל-10 השכבות העליונות של MobileNetV2 בקצב למידה נמוך כדי להתאים את חילוף המאפיינים למשימת איתור הלוחיות הספציפית. האימון בוצע באמצעות אופטימיזר AdamW הכולל weight decay לאורך כל שלושת השלבים, לצמצום התאמת יתר.

הבחירה במבנה זה של אימון הדרגתי נבעה מקושי שנצפה באימון ראשוני ישיר עם GIoU. כאשר התיבות החזויות בתחילת האימון אינן חופפות את תיבות המטרה, רכיב ה-GIoU מספק גרדיאנטים רועשים ולא יציבים, הדוחפים את קואורדינטות התיבה התוחמת לערכי קיצון ומרוויים את פונקציית ה-Sigmoid. מצב זה עלול ליצור "תיבה הפוכה" (שבה  $x_{max}$  קטן מ- $x_{min}$ ), שבה שני רכיבי ההפסד מאבדים את הגרדיאנט בו-זמנית: רכיב ה-GIoU מתאפס, ורכיב ה-Huber מתאפס אף הוא עקב רוויית ה-Sigmoid מה שהוביל לכך שהאימון נתקע ללא סיגנל שיחלץ אותו. לכן, שימוש ראשוני ב-Huber Loss בלבד אפשר למודל ללמוד מיקום בסיסי של הלוחית והביא את התיבות לאזור חופף, ורק לאחר מכן רכיב ה-GIoU שימש לשיפור דיוק החפיפה - בשלב שבו הוא פועל באזור היעיל שלו.

## 3.2 עיבוד מקדים של אזור הלוחית Preprocessing

לאחר איתור התיבה התוחמת, בוצע שלב עיבוד מקדים שמטרתו להכין את אזור הלוחית לקריאת התווים. שלב זה חיוני מכיוון שהתיבה החזויה היא תיבה מלבנית המקבילה לצירי התמונה, בעוד שבפועל הלוחית עשויה להופיע בזווית, בפרספקטיבה לא ישרה, בתאורה לא אחידה או באיכות נמוכה.

תחילה בוצע חיתוך של אזור הלוחית מתוך תמונת הרכב בהתאם לתיבה התוחמת שהתקבלה ממודל ה-Detection. לאחר מכן הופעל אלגוריתם Canny לזיהוי קצוות, ובהמשך נעשה שימוש ב-approxPolyDP לצורך קירוב קווי המתאר ואיתור ארבע פינות הלוחית. כאשר נמצאו ארבע פינות מתאימות, בוצעה טרנספורמציה פרספקטיבה מסוג Point Perspective Warp, שמטרתה ליישר את הלוחית וליצור ייצוג חזיתי ואחיד יותר שלה. במקרים שבהם לא אותרו ארבע פינות באופן יציב, בוצע שינוי גודל ישיר של החיתוך, כך שה-Pipeline יוכל להמשיך לפעול גם במקרים מאתגרים.

לאחר יישור הלוחית, התמונה הומרה לגונוי אפור כדי לצמצם את ממד הקלט ולהתמקד במבנה הצורני של התווים. בהמשך הופעל CLAHE, Contrast Limited Adaptive Histogram Equalization, לשיפור הניגודיות המקומית בתמונה. פעולה זו נועדה להבליט את ההבדלים בין התווים לבין הרקע, במיוחד במקרים של תאורה לא אחידה או תמונות באיכות נמוכה. לבסוף, כל חיתוך הותאם לגודל קבוע של  $64 \times 256$  פיקסלים, שהוא גודל הקלט הנדרש למודל ה-OCR.

## 3.3 מודל זיהוי התווים OCR

בשלב השלישי בוצע זיהוי רצף התווים שעל גבי הלוחית באמצעות מודל Convolutional Recurrent Neural Network (CRNN). ארכיטקטורה זו מתאימה למשימות OCR משום שהיא משלבת בין חילון מאפיינים חזותיים באמצעות שכבות קונבולוציה לבין למידת תלות סדרתית בין תווים באמצעות שכבות recurrent.


קלט המודל הוא תמונת לוחית בגונוי אפור בגודל  $64 \times 256$  פיקסלים. תחילה, התמונה עוברת דרך ארבעה בלוקים קונבולוציוניים, אשר מקטינים את גובה התמונה מ- $64$  ל- $4$  ואת רוחבה מ- $256$  ל- $32$ . כתוצאה מכך מתקבל ייצוג סדרתי באורך 32 צעדי זמן, שבו ציר הרוחב של התמונה משמש כציר הזמן. רצף זה מוזן לשתי שכבות Bidirectional LSTM, שכל אחת מהן כוללת 256 יחידות, במטרה ללמוד את ההקשר הסדרתי בין אזורים סמוכים בלוחית.

פלט הרשת מתקבל באמצעות שכבת Dense המייצרת לוגיטים עבור 37 מחלקות: 26 אותיות באנגלית, 10 ספרות, ותו Blank הנדרש לצורך Connectionist Temporal Classification (CTC). השימוש ב-CTC מאפשר לאמן את המודל על רצף התווים המלא של הלוחית, ללא צורך בתיוג מדויק של מיקום כל תו בתוך התמונה. כלומר, המודל לומד למפות בין רצף מאפיינים חזותיים לבין רצף תווים, גם כאשר אין מידע מפורש על גבולות התווים.

במהלך האימון נמצא כי CTC Loss לבדו אינו מדד מספק לבחירת המודל, משום שהוא מודד את ביטחון הרשת בהתאמה לרצף ולא את נכונות הקריאה בפועל. במקרים מסוימים ערך ה-Loss ירד בעוד שהמודל עדיין לא הצליח לפענח רצפים נכונים - למעשה נצפה שה-val\_loss מגיע למינימום דווקא בשלב מוקדם של האימון, לפני שהמודל לומד לקרוא. לכן נכתב Callback ייעודי הרץ בסוף כל epoch, המבצע Greedy Decode לתחזיות המודל - תהליך הממיר את פלט הרשת (הציון לכל תו בכל צעד זמן) למחרוזת טקסט, על ידי בחירת התו בעל הציון הגבוה ביותר בכל צעד וניקוי כפילויות ותווי Blank לפי כללי CTC - ומשווה את המחרוזת לרצף האמיתי לצורך חישוב Exact Match. מדד זה בודק האם רצף התווים החזוי זהה לחלוטין לרצף האמיתי, ולכן הוא מתאים במיוחד למשימת קריאת לוחיות רישוי. בהתאם לכך, בחירת המודל הסופי התבססה על Exact Match ולא רק על ערך פונקציית ההפסד.

## למידה עמוקה

אחד האתגרים המרכזיים באימון מודל ה-OCR היה תופעת prior-collapse. בתחילת האימון המודל עשוי להקטין את ערך ה-CTC Loss באמצעות חיזוי חוזר של תו ה-Blank או של רצפים שכיחים, במקום ללמוד לקרוא את הלוחית בפועל. במצב זה ה-CTC Loss עשוי לרדת, אך דיוק ה-Exact Match נשאר נמוך מאוד. תופעה זו הייתה משמעותית במיוחד בשל גודל מאגר האימון המצומצם יחסית.



נבחנה גם הגדלה של מספר צעדי הזמן  $T$ , מתוך הנחה שרזולוציה אופקית גבוהה יותר עשויה לשפר הבחנה בין תווים דומים כגון  $B/8$  או  $O/0$ . עם זאת, בפועל הגדלת מספר צעדי הזמן הגבירה את הקושי להיחלץ מ-prior-collapse במסגרת גודל הנתונים ותקציב האימון הקיימים. לכן נשמרה תצורת ה-OCR המקורית, אשר סיפקה יציבות טובה יותר ביחס לחלופות שנבדקו.

### 3.4 שחזוריות ושונות בין ריצות

לצורך שיפור השחזוריות נקבע seed אחיד באמצעות `keras.utils.set_random_seed`, וכן הופעל `tf.config.experimental.enable_op_determinism` הגדרות אלו נועדו לצמצם שונות הנובעת מאתחול משקלים, ערוב נתונים ותהליכי אוגמנטציה. עם זאת, באימון רשתות עמוקות על GPU עשויה להישאר שונות שיורית הנובעת מאופי החישוב המקבילי ומהרגישות של המודלים לנקודת ההתחלה. רגישות זו בולטת במיוחד במודל ה-OCR, שבו מהירות ההיחלצות מתופעת ה-prior-collapse תלויה באתחול האקראי (כמתואר בסעיף ה-OCR), ומכאן חלק מהשונות שנצפתה בביצועיו בין ריצות.

בפועל נצפתה שונות מסוימת בין ריצות אימון, הן במודל ה-Detection והן במודל ה-OCR. שונות זו אינה משנה את המסקנה המרכזית של הפרויקט, אך היא מחייבת להציג את התוצאות כריצה מייצגת ולא כערך מוחלט יחיד. לכן, התוצאות המדווחות בדוח מתייחסות לריצת אימון מייצגת, תוך התייחסות למגמות העקביות שנצפו: שיפור איכות האיתור תרם לשיפור ביצועי ה-Pipeline המלא, ובדיקות על Ground Truth crops אפשרו להפריד בין מגבלת האיתור לבין מגבלת קריאת התווים.

## 4. תוצאות

הערכת ביצועי המערכת בוצעה בהתאם למבנה ה-Pipeline. עבור מודל ה-Detection נמדדו Mean IoU ו-  $\text{Accuracy@IoU} \geq 0.5$ , ועבור מודל ה-OCR והמערכת המלאה נמדדו Exact Match ו- Character Error Rate (CER). מדד Exact Match בודק האם רצף הלוחית זוהה במלואו, ואילו CER מודד את שיעור השגיאות ברמת התו.

### 4.1 תוצאות מודל האיתור Detection

בהערכה על סט המבחן, מודל האיתור הגיע ל- Mean IoU של 0.348 ול-  $\text{Accuracy@IoU} \geq 0.5$  של 0.255. כלומר, כ-25.5% מהתיבות החזויות עברו את סף החפיפה 0.5, הנחשב לסף מינימלי לחיתוך איכותי של הלוחית לצורך המשך קריאה.

תוצאות אלו מצביעות על כך שהמודל מצליח בחלק מהמקרים לאתר את האזור הכללי של הלוחית, אך מתקשה לדייק את גבולות התיבה. מגבלה זו קשורה לארכיטקטורת האיתור שנבחרה: רגרסיה לתיבה יחידה באמצעות MobileNetV2 ו- Global Average Pooling. גישה זו פשוטה ויעילה, אך עלולה לאבד מידע מרחבי עדין הדרוש לאיתור מדויק של גבולות הלוחית.

### 4.2 תוצאות מודל זיהוי התווים OCR

מודל ה-OCR נבחן בשני תרחישים. תחילה, הוא נבדק על חיתוכי ה-Test שעברו את שלב ה-Preprocessing, בנפרד משגיאות ה-Detector בזמן אמת. בתרחיש זה התקבל Exact Match של 0.368 ו- CER של 0.175.

בנוסף, כדי לבדוד את יכולת הקריאה של ה-OCR משגיאות האיתור, המודל נבדק על חיתוכי Ground Truth, כלומר על תיבות האמת מתוך האנוטציות. בתרחיש זה התקבל Exact Match של 0.387 ו- CER של 0.187. תוצאה זו מייצגת את ביצועי ה-OCR כאשר שגיאת האיתור מוסרת מהמערכת.

הפער בין Exact Match לבין CER מלמד כי חלק ניכר מהשגיאות אינן קריאה שגויה לחלוטין של הלוחית, אלא טעויות נקודתיות ברמת תו אחד או מספר קטן של תווים. כלומר, גם כאשר הרצף אינו זהה לחלוטין ללוחית האמיתית, התחזית במקרים רבים עדיין קרובה יחסית לטקסט הנכון.

### 4.3 תוצאות המערכת המלאה End-to-End Pipeline

בתרחיש המלא, תמונת רכב הוזנה למערכת ועברה ברצף את שלבי האיתור, העיבוד המקדים וזיהוי התווים באמצעות OCR.

בבדיקה זו התקבל Full-plate Exact Match של 0.094 ו- CER של 0.551 על סט המבחן. המשמעות היא שבכ-9.4% מהדוגמאות בלבד המערכת הצליחה להחזיר רצף לוחית זהה לחלוטין לאמת. זהו מדד מחמיר, מאחר שטעות בתו אחד בלבד גורמת לדוגמה להיחשב כשגויה.

לאורך פיתוח הפרויקט נרשם שיפור הדרגתי בביצועי ה-End-to-End: מ-0.074 בגרסה הראשונית, ל-0.139 לאחר התאמת שלבי ה-Preprocessing ובחירת מודל OCR לפי Exact Match, ועד לשיא של **0.231** לאחר שיפור רכיב האיתור באמצעות רזולוציית קלט של 384 פיקסלים ואוגמנטציות פוטומטריות. עם זאת, בהרצה הסופית

## למידה עמוקה

הנוכחית התקבל Detector חלש יותר, שבו רק 25 מתוך 106 תיבות עברו את סף  $\text{IoU} \geq 0.5$ , ולכן ביצועי ה-End-to-End ירדו ל-0.094.

### 4.4 ניתוח צווארי בקבוק Bottleneck Analysis

כדי להבין איזה רכיב מגביל את המערכת, נבחנו ביצועי ה-End-to-End לפי איכות התיבה שחזה מודל האיתור. כאשר התיבה הייתה איכותית יחסית, כלומר  $\text{IoU} \geq 0.5$ , התקבל Exact Match של 0.360 ו-CER של 0.166. לעומת זאת, כאשר התיבה הייתה חלשה יותר, כלומר  $\text{IoU} < 0.5$ , התקבל Exact Match של 0.012 בלבד ו-CER של 0.670.

פער זה מראה באופן ברור כי איכות ה-Detection משפיעה ישירות על הצלחת קריאת הלוחית. כאשר החיתוך מדויק, ה-OCR מתקרב לביצועיו בתרחיש Ground Truth. כאשר החיתוך אינו מדויק, הוא עלול לכלול רק חלק מהלוחית, רקע מיותר או עיוות פרספקטיבי, ולכן גם מודל OCR תקין מתקשה לקרוא את התווים.

מכאן עולה כי רכיב ה-Detection הוא צוואר הבקבוק המרכזי של המערכת. עם זאת, מאחר שגם על חיתוכי Ground Truth ה-OCR הגיע ל-Exact Match של 0.387 בלבד, ניתן לראות כי ה-OCR מגבלה משנית נוספת.

### 4.5 שונות בין ריצות ואופן דיווח התוצאות

במהלך הניסויים נצפתה תנודתיות בין ריצות, גם לאחר שימוש ב-`keras.utils.set_random_seed` וב-`tf.config.experimental.enable_op_determinism`. במחברת מצוין כי מודל האיתור עשוי להשתנות בכ- $\pm 0.08$  ב-Mean IoU בין ריצות. תנודתיות זו משפיעה באופן ישיר על ביצועי ה-End-to-End, משום שה-OCR תלוי באיכות החיתוך שמתקבל משלב האיתור.

לכן, בפרק זה מוצגות תוצאות ההרצה הסופית שצורפה למחברת, לצד ציון השיא שהתקבל במהלך הפיתוח. הבחנה זו מאפשרת לדווח באופן שקוף: הביצועים הנוכחיים משקפים את הריצה המצורפת, ואילו השיא של 0.231 מדגים את פוטנציאל השיפור כאשר רכיב האיתור חזק יותר.

### 4.6 סיכום התוצאות

| תוצאה | מדד                         | רכיב נבדק           |
|-------|-----------------------------|---------------------|
| 0.348 | Test Mean IoU               | Detection           |
| 0.255 | Accuracy@IoU $\geq 0.5$     | Detection           |
| 0.368 | Exact Match על חיתוכי Test  | OCR                 |
| 0.175 | CER על חיתוכי Test          | OCR                 |
| 0.387 | Exact Match על Ground Truth | OCR                 |
| 0.187 | CER על Ground Truth         | OCR                 |
| 0.094 | Full-plate Exact Match      | End-to-End Pipeline |
| 0.551 | CER                         | End-to-End Pipeline |
| 0.231 | שיא במהלך הפיתוח            | End-to-End Pipeline |

לסיכום, תוצאות ההרצה הסופית מראות כי מודל ה-OCR מסוגל לקרוא לוחיות ברמה סבירה כאשר הוא מקבל חיתוך איכותי, אך ביצועי המערכת המלאה נפגעים משמעותית כאשר שלב האיתור אינו מדויק. לכן, שיפור רכיב ה-Detection הוא הכיוון המרכזי לשיפור עתידי של המערכת, לצד הרחבת מאגר הנתונים ושיפור מודל ה-OCR.



## 5. סיכום ומסקנות

בפרויקט זה פותחה מערכת קצה-לקצה לזיהוי אוטומטי של לוחיות רישוי ברכבים הודיים. המערכת נבנתה כ-Pipeline מודולרי הכולל שלושה שלבים עיקריים: איתור מיקום הלוחית בתמונה, עיבוד מקדים של אזור הלוחית, וזיהוי רצף התווים באמצעות OCR. בניגוד לגישות המבוססות על גלאי עצמים מוכנים מראש, המערכת נבנתה באמצעות TensorFlow/Keras ו-OpenCV, מתוך מטרה להבין את תרומתו של כל שלב ולבחון את מגבלותיו באופן עצמאי.

תוצאות הפרויקט הראו כי ניתן לממש Pipeline מלא המבצע את כלל שלבי המשימה, אך ביצועי המערכת עדיין מוגבלים. ניתוח התוצאות הצביע על כך שרכיב ה-Detection הוא צוואר הבקבוק המרכזי: כאשר מודל ה-OCR הופעל על חיתוכי Ground Truth, כלומר ללא שגיאת איתור, התקבל Exact Match של כ-0.46, בעוד שבמערכת המלאה, המבוססת על תיבות שחזה מודל ה-Detection, התקבל Exact Match של כ-0.23 בלבד. פער זה מלמד כי איכות איתור הלוחית משפיעה ישירות על יכולת קריאת התווים בהמשך ה-Pipeline.

עם זאת, מודל ה-OCR עצמו אינו מהווה רכיב מושלם, שכן גם בתרחיש שבו הוזנו לו חיתוכי Ground Truth הוא לא הגיע לדיוק מלא. לכן ניתן להסיק כי שגיאות המערכת נובעות משילוב של שני גורמים: חיתוכים לא מדויקים הנגרמים משלב האיתור, לצד מגבלות של מודל קריאת התווים, בעיקר במקרים של תמונות מטושטשות, לוחיות באיכות נמוכה או תווים בעלי דמיון חזותי גבוה.

מסקנה נוספת היא שגודל ואיכות מאגר הנתונים השפיעו על יציבות המודלים ועל רמת הביצועים. אף שבוצעו ניקוי נתונים, הסרת כפילויות ומניעת זליגת מידע, המאגר הסופי כלל 1,092 דוגמאות בלבד, מתוכן 872 דוגמאות לאימון. גודל זה מוגבל יחסית לאימון מערכת ALPR מלאה, במיוחד כאשר קיימת שונות גבוהה בתנאי הצילום ובאיכות התמונות. בנוסף, נצפתה שונות בין ריצות אימון שונות, גם לאחר קיבוע seed ושימוש ב-determinism, ולכן התוצאות דווחו כריצה מייצגת תוך התייחסות לתנודתיות בין הרצות.

לסיכום, הפרויקט הדגים בנייה וניתוח של מערכת ALPR מלאה, תוך הבנה של יחסי התלות בין שלבי ה-Detection, Preprocessing וה-OCR. הכיוון המרכזי לשיפור עתידי הוא שיפור רכיב האיתור, למשל באמצעות גלאי עצמים ייעודי ומדויק יותר, לצד הרחבת מאגר הנתונים ושיפור מודל ה-OCR באמצעות אוגמנטציות חזקות יותר Beam Search decoding, או Backbone מתקדם יותר. שיפורים אלו צפויים לשפר את איכות החיתוך ואת דיוק קריאת הלוחיות במערכת המלאה.